

Strukturgleichungsmodelle

Sozialwissenschaftliche Forschungsmethoden für
Fortgeschrittene

Dr. André Calero Valdez

Wiederholung

Uns interessiert eigentlich die Wirkung zwischen den "latenten" Variablen.

Nachteile

Viele Schritte um zum Ergebnis zu kommen.

1. Faktorenanalysen
2. Reliabilitätsanalysen
3. Hypothesentests

Keine Kausalbeziehungen

Erkenntnisse sind immer Assoziationen und keine kausalen Beziehungen!

Keine Mediationsanalyse

Im schrittweisen Erklären der einzelnen Modellteile gehen Informationen verloren.

Assoziation und Kausalität

Jede Regression lässt sich auch "rückwärts" rechnen.

LINEAR REGRESSION

Model Fit Measures

Model	R	R ²
1	0.3077638	0.09471855

MODEL SPECIFIC RESULTS

MODEL 1

Model Coefficients - cse

Assoziation und Kausalität

Jede Regression lässt sich auch "rückwärts" rechnen.

LINEAR REGRESSION

Model Fit Measures

Model	R	R ²
1	0.3077638	0.09471855

MODEL SPECIFIC RESULTS

MODEL 1

Model Coefficients - age

Umkehrbarkeit von lineare Gleichungen

Y als abhängige Variable

$$y = b \times x + c$$

Umkehrbarkeit von lineare Gleichungen

Y als abhängige Variable


$$y = b \times x + c$$

X als abhängige Variable

$$x = \frac{y - c}{b}$$


Kausale Modelle?

Kann ich ein Modell formulieren, in dem eine Änderung der unabhängigen Variablen eine Änderung der abhängigen Variable "verursacht" aber nicht umgekehrt?



Kausale Modelle?

Kann ich ein Modell formulieren, in dem eine Änderung der unabhängigen Variablen eine Änderung der abhängigen Variable "verursacht" aber nicht umgekehrt?



Mathematik kennt keine "Richtung"

Randomized Controlled Trial

Goldstandard der kausalen Statistik

Doppelblind Gruppierung

- Es werden zwei Gruppen gebildet: **Test**gruppe und **Kontroll**gruppe
- Gruppenzuweisung erfolgt zufällig und doppelblind

Testdurchführung

- Testgruppe bekommt die Veränderung
- Kontrollgruppe bekommt die Veränderung nicht

Auswertung

Beispiel

Pfizer/BioNTech Impfstoff ([Link zur Originalstudie](#))

Beispiel

Pfizer/BioNTech Impfstoff ([Link zur Originalstudie](#))

Strukturgleichungsmodelle

Observational Study

Häufig können Veränderungen nur beobachtet und nicht verursacht werden.

Was tun?

Voraussetzungen für kausale Erkenntnis in Beobachtungsstudien

1. Gute theoretische Herleitung der Modellannahmen
2. Entwurf eines Modells, dass andere Interpretationen verhindert.

Verschiedene Ansätze:

Structural Equation Modelling (SEM)

Zwei unterschiedliche Verfahren:

1. Kovarianzbasierte Modelle (CB-SEM)
2. Varianzbasierte Modelle (VB-SEM)

Beide Modellarten sind graphische Modelle!

Structural Equation Modelling (SEM)

Zwei unterschiedliche Verfahren:


1. Kovarianzbasierte Modelle (CB-SEM)
2. Varianzbasierte Modelle (VB-SEM)

Beide Modellarten sind graphische Modelle!

Gemeinsamkeiten

1. Latente Variablen werden als Ellipsen dargestellt
2. Manifeste Variablen werden als Rechtecke dargestellt
3. Kausale Beziehungen werden als Pfeile dargestellt

Graphische Modelle



Manifest Variablen vs. Latente Variablen

- Exogene Variablen: Werden nur durch Manifestvariablen bestimmt
- Endogene Variablen

SEM prüft alle Pfade in einem mathematischen Modell

Mobi Dataset

Daten einer Mobiltelefon Nutzerbefragung (n=250).

1. Expectation - Erwartungen gegenüber dem Anbieter
2. Satisfaction - Zufriedenheit mit dem Anbieter
3. Loyalty - Loyalität zum Anbieter
4. Complaints - Beschwerden beim Anbieter
5. etc.

Mobi Dataset

Daten einer Mobiltelefon Nutzerbefragung (n=250).

1. Expectation - Erwartungen gegenüber dem Anbieter
2. Satisfaction - Zufriedenheit mit dem Anbieter
3. Loyalty - Loyalität zum Anbieter
4. Complaints - Beschwerden beim Anbieter
5. etc.


SEM Modelle auf Mobi Daten

Vorgehensweise

6. Hypothese ist eine Modellkombination aus
 1. **Messmodell:** Welche Manifestvariablen messen welche latenten Variablen
 2. **Strukturmodell:** Welche Beziehungen bestehen zwischen latenten Variablen
7. Es werden immer alle Pfade gleichzeitig "geschätzt".

Beispiel-Modell

Strukturmodell




Pfade sind dabei immer (multiple) lineare Regressionen.

$$\text{z.B. } \textit{Loyalty} = b_{sl} \times \textit{Satisfaction} + b_{el} \times \textit{Expectation} + c + \epsilon$$

Beispiel-Modell

Strukturmodell



Pfade sind dabei immer (multiple) lineare Regressionen.

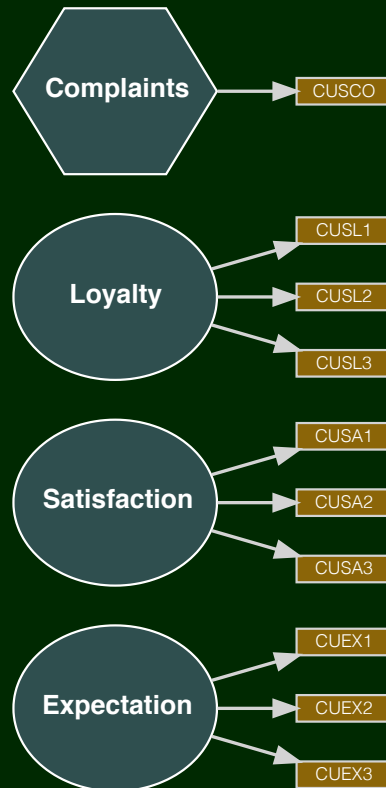
z.B. $Loyalty = b_{sl} \times Satisfaction + b_{el} \times Expectation + c + \epsilon$

Was nicht offensichtlich ist:


$Loyalty = b_{sl} \times Sat. + b_{el} \times Exp. + b_{cl} \times Complaints + c + \epsilon$ und

Beispiel-Modell

Messmodell



Beispiel-Modell



Model berechnen

Varianz-basiertes Modell mit PLS-Schätzung (partial least squares)

Model analysieren

Messmodellgüte prüfen

Results from package `seminr` (2.0.3)

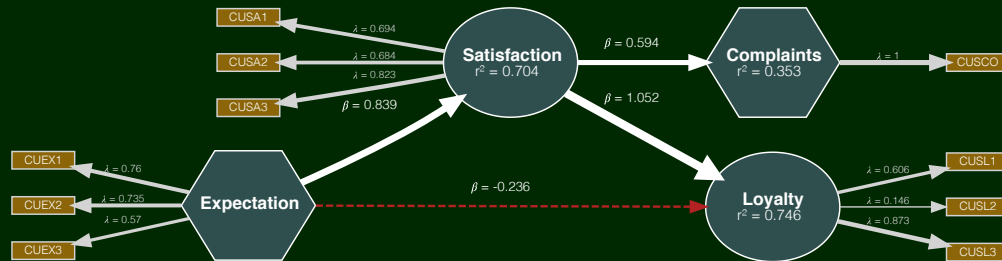
Path Coefficients:

	Satisfaction	Loyalty	Complaints
R ²	0.704	0.746	0.353
AdjR ²	0.703	0.744	0.350
Expectation	0.839	-0.236	.
Satisfaction	.	1.052	0.594

Reliability:

	alpha	rhoC	AVE	rhoA
Expectation	0.452	0.732	0.481	0.468
Satisfaction	0.779	.	0.543	0.787
Loyalty	0.472	.	0.383	0.752

Model plotten



Model optimieren

Manifest Variablen entfernen

Model prüfen

Results from package `seminr` (2.0.3)

Path Coefficients:

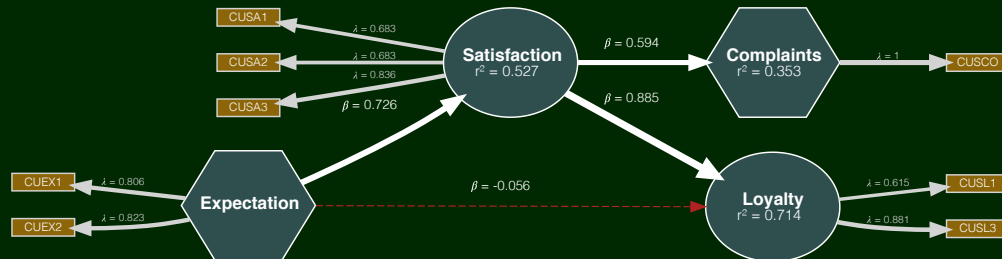
	Satisfaction	Loyalty	Complaints
R ²	0.527	0.714	0.353
AdjR ²	0.525	0.712	0.351
Expectation	0.726	-0.056	.
Satisfaction	.	0.885	0.594

Reliability:

	alpha	rhoC	AVE	rhoA
Expectation	0.491	0.797	0.663	0.492
Satisfaction	0.779	.	0.544	0.790
Loyalty	0.703	.	0.577	0.765
Complaints	1.000	1.000	1.000	1.000

Alpha, rhoC, and rhoA should exceed 0.7 while AVE should exceed 0.5

Model Plot



Bootstrapping

Notwendig für zufallsabhängige Schätzung

		Original Est.	Bootstrap Mean	Bootstrap SD	T Stat.	2.
Expectation	-> Satisfaction	0.735	0.744	0.109	6.736	
Expectation	-> Loyalty	0.607	0.616	0.107	5.655	
Expectation	-> Complaints	0.357	0.369	0.100	3.559	
Satisfaction	-> Loyalty	0.855	0.859	0.078	10.914	
Satisfaction	-> Complaints	0.588	0.591	0.059	9.979	
Loyalty	-> Complaints	0.465	0.469	0.079	5.917	

Diskriminanzvalidität

Hetero-Trait-Mono-Trait Ratio

Misst wie ähnlich sich Konstrukte sind. Ideal ist HTMT < 1.


Diskriminanzvalidität

Hetero-Trait-Mono-Trait Ratio

Misst wie ähnlich sich Konstrukte sind. Ideal ist HTMT < 1.

			Original Est.	Bootstrap Mean	Bootstrap SD	T Stat.	2.
Expectation	->	Satisfaction	0.735	0.744	0.109	6.736	
Expectation	->	Loyalty	0.607	0.616	0.107	5.655	
Expectation	->	Complaints	0.357	0.369	0.100	3.559	
Satisfaction	->	Loyalty	0.855	0.859	0.078	10.914	
Satisfaction	->	Complaints	0.588	0.591	0.059	9.979	
Loyalty	->	Complaints	0.465	0.469	0.079	5.917	

Bootstrapped Model Plot



Was kann schief gehen?

Messmodell passt nicht?

Egal wie viel man weglässt, immer bleibt etwas unter den Schwellen. KEIN SEM.

Modell ist underspezifiziert

Die Anzahl an Daten und Manifestvariablen reichen nicht aus, um das Modell zu schätzen.

SEM benötigt...

- gute Theoriearbeit
- kausale Hypothesen
- relativ große Stichproben

Was gibt es noch?

Higher Order Constructs

- Konstrukte setzen sich aus Unterkonstrukten zusammen.
 - z.B.: Intelligenz besteht aus kristalliner und fluider Intelligenz
- Beide Unterkonstrukte müssen wieder einzeln gemessen werden.
- Keine Manifestmessung der Oberkonstrukte.

Interaktionseffekte

- Eine Variable kann den Einfluss einer Variable auf eine andere **moderieren**.
 - z.B. "Die Kontrollüberzeugung im Umgang mit Technik beeinflusst mit steigendem Alter die Akzeptanz mobiler Robotik."

CB-SEM vs. VB-SEM

VB-SEM (PLS-SEM, SmartPLS, PLSc, SEMinR, etc.)

- geeignet für kleinere Stichproben ($N=150-250$)
- geeignet für Exploration kausaler Modelle

CB-SEM (AMOS, Lisrel, lavaan, etc.)

- konfirmatorischer Ansatz
- noch größere Stichproben ($N>500$)
- nur Latent-Faktor Messmodelle
- Zusätzlich Kovarianzen zwischen Items verschiedener Konstrukte erlaubt
 - müssen aber im Modell angegeben werden!

Beispiel mit SEMinR


Results from package seminr (2.0.3)
Estimation used package seminr (2.0.3)

Fit metrics:

npars	fmin	pnfi	logl	aic	bic	ntotal	bic2
20.000	0.067	0.542	-3773.665	7587.330	7657.759	250.000	7594.357
ecvi							
0.293							

	metric	scaled	robust
cfi	0.972	0.973	0.978
tli	0.952	0.953	0.962
nnfi	0.952	0.953	0.962
rni	0.972	0.973	0.978
rmsea	0.066	0.052	0.058
rmsea.ci.lower	0.033	0.016	0.010
rmsea.ci.upper	0.097	0.082	0.095

Model Plot



Zusammenfassung

Zwei Arten von Strukturgleichungsmodellen

- Kovarianzbasierte Verfahren
- Varianzbasierte Verfahren

Notwendige Schritte

1. Konstruktion und Überprüfung des Messmodells
2. Konstruktion und Überprüfung des Strukturmodells
3. Schätzen und Prüfen des Gesamt-Modells
4. Bootstrapping

Achtung!

Zurück zur Übersicht